

# Redes neuronales

Parte 2

# Redes neuronales


<https://playground.tensorflow.org/>

# Redes neuronales

- Hasta ahora, hemos visto como usar redes neuronales para modelar información.
- Ya hemos visto que las neuronas pueden ser usadas fácilmente para resolver tareas de regresión o clasificación lineal.
- Incluso unimos varias neuronas para formar un red e incluimos las funciones de activación para realizar tareas más complejas.
- El detalle es nosotros debíamos modificar los parámetros de la red.

# Redes neuronales

- Entre las décadas de 1950 y 1960 el científico Frank Rosenblatt creó el concepto de Perceptrón.



- Como ocurre con frecuencia, se pensó que el perceptrón ayudaría a resolver todos nuestros problemas.
- Pronto se empezaron a descubrir limitaciones (solo aplica a problemas lineales).

# Redes neuronales

- En 1965 se propone el esquema de multi-capas, aparece el concepto de capas de entrada, oculta y salida.
- Lamentablemente, el valor de los pesos de cada neurona se asignaban manualmente.
- Cuantos más perceptrones en las capas, mucho más difícil conseguir los pesos para obtener salidas deseadas.

# Redes neuronales

- En 1969, Marvin Minsky y Seymour Papert publican el libro “Perceptrons: an introduction to computational geometry”.
- En este libro demuestran matemáticamente las fortalezas y las limitaciones del perceptrón.
- Una de las limitaciones estaba relacionada con el cálculo de algunos predicados, como la función XOR.

# Redes neuronales

- A partir de su publicación y debate hubo un corte en el financiamiento al estudio de la inteligencia artificial, en particular a los relacionados con redes neuronales.
- Esto dio origen a un periodo de más de 15 años conocido como el invierno de la IA.


# Redes neuronales

- Afortunadamente, en 1986, David E. Rumelhart, Geoffrey E. Hinton y Ronald J. Williams, publican el artículo “Learning representations by back-propagating errors”.
- Básicamente, muestran un algoritmo de aprendizaje que le permite a una red neuronal auto-ajustar sus parámetros.
- El nombre del algoritmo fue backpropagation (retro-propagación).

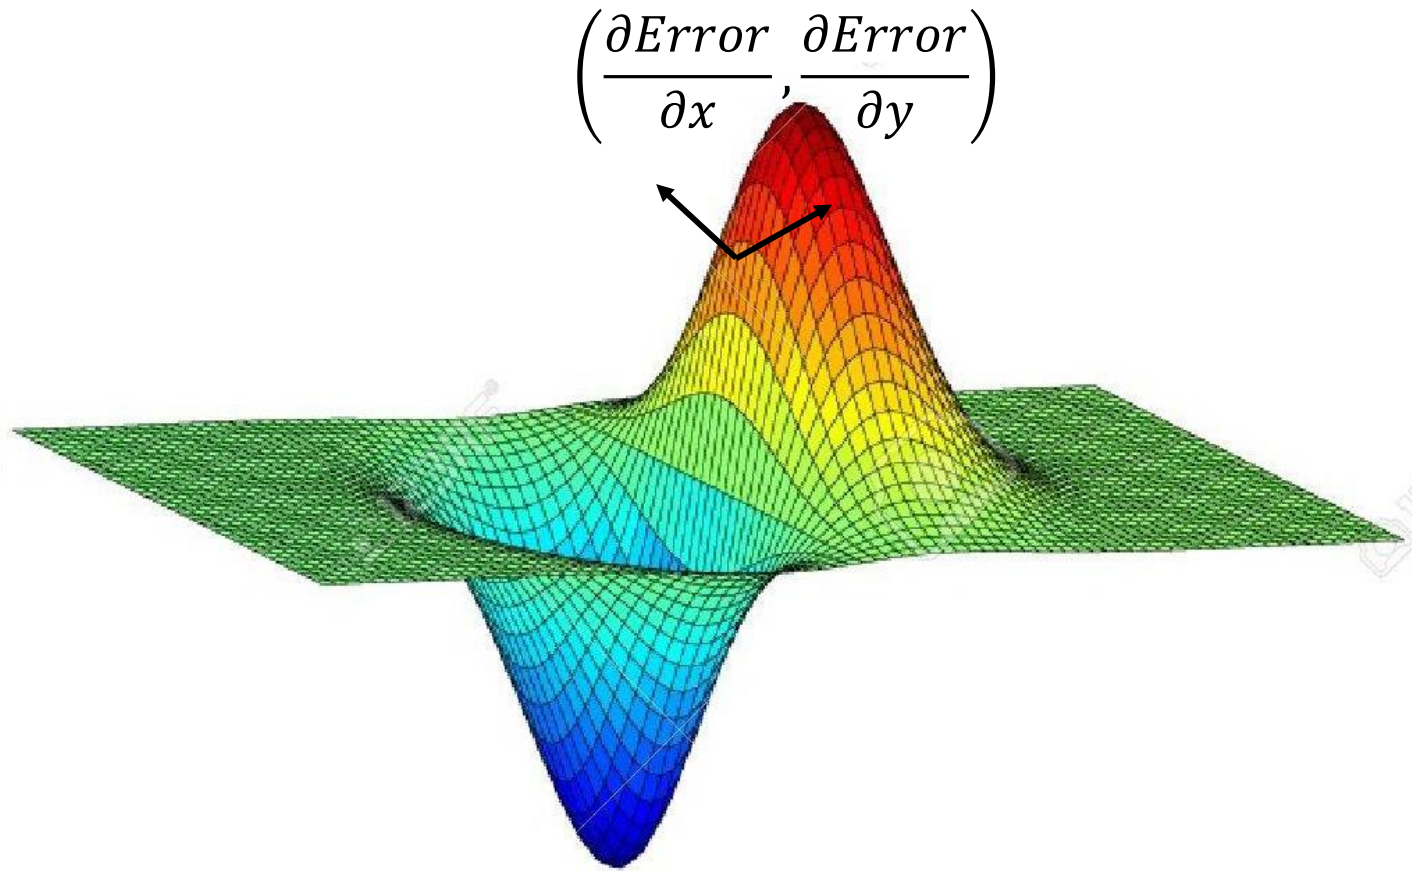


# Ejemplo


- Explicar cómo mejorar el proceso productivo en una compañía ideal con una jerarquía bien detallada.




# Backpropagation



# Backpropagation




# Backpropagation




# Backpropagation

- Considere una red neuronal que inicia con parámetros aleatorios.
- Por lo tanto para los datos de entrada obtendremos salidas aleatorias y posiblemente un error alto




# Backpropagation

- Considere una red neuronal que inicia con parámetros aleatorios.
- Por lo tanto para los datos de entrada obtendremos salidas aleatorias y posiblemente un error alto



# Backpropagation


- Ahora, para tratar de mejorar el desempeño de la red, vamos a calcular las derivadas parciales de cada uno de los parámetros.



$$\frac{\partial \mathcal{C}}{\partial w} \text{ y } \frac{\partial \mathcal{C}}{\partial b}$$

# Backpropagation

- Debemos empezar desde la última capa.
- Vamos a colocar un identificador para reconocer la capa en la cual estamos trabajando. Supongamos una red con L capas.




$$\frac{\partial \mathcal{C}}{\partial w^L} \text{ y } \frac{\partial \mathcal{C}}{\partial b^L}$$




# Backpropagation

- Ahora veamos cómo calculamos las derivadas parciales.
- Empecemos con la última capa.



# Backpropagation

- Veamos, en la última capa se tendría la transformación lineal de la neurona.
- $Z^L = W^L X + b^L$
- Luego se aplicaría la función de activación
- $a(Z^L) = a(W^L X + b^L)$
- Por último, se calcula el costo o error
- $C(a(Z^L)) = Error$



$\rightarrow Y \rightarrow \text{COSTO}$   
 $\rightarrow Z^L \rightarrow a(Z^L) \rightarrow C(a(Z^L))$

# Backpropagation

- Recordemos que:
- $Z^L = W^L a^{L-1} + b^L; \quad C(a^L(Z^L))$
- Ahora podemos aplicar la regla de la cadena y obtener:
- $$\frac{\partial C}{\partial w^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial w^L}$$
- $$\frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial b^L}$$

# Backpropagation

- Ahora podemos aplicar la regla de la cadena y obtener:

- $$\frac{\partial C}{\partial w^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial w^L}$$

- $$\frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial b^L}$$

- Recordemos que:

- $$z^L = W^L a^{L-1} + b^L; \quad C(a^L(z^L))$$

- Si la función de costo es el error cuadrático medio tenemos lo siguiente:

- $$C(a_j^L) = \frac{1}{2} \sum_j (y_j - a_j^L)^2$$

- Entonces,

- $$\frac{\partial C}{\partial a^L} = (a_j^L - y_j)$$

# Backpropagation

- Ahora podemos aplicar la regla de la cadena y obtener:

- $$\frac{\partial C}{\partial w^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial w^L}$$

- $$\frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial b^L}$$

- Recordemos que:

- $$z^L = W^L a^{L-1} + b^L; \quad C(a^L(z^L))$$

- Si la función de activación es la sigmoide tenemos lo siguiente:

- $$\frac{\partial a^L}{\partial z^L} = a^L(z^L)(1 - a^L(z^L))$$

# Backpropagation

- Ahora podemos aplicar la regla de la cadena y obtener:

- $$\frac{\partial C}{\partial w^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial w^L}$$

- $$\frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial b^L}$$

- Recordemos que:

- $$z^L = W^L a^{L-1} + b^L; \quad C(a^L(z^L))$$

- Por último tenemos:

- $$z^L = \sum_i a_i^{L-1} w_i^L + b^L$$

- Por lo tanto,

- $$\frac{\partial z^L}{\partial b^L} = 1$$

- $$\frac{\partial z^L}{\partial w^L} = a_i^{L-1}$$

# Backpropagation

- Ahora podemos aplicar la regla de la cadena y obtener:

- $\frac{\partial C}{\partial w^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} a_i^{L-1}$

- $\frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} 1$

- Recordemos que:

- $Z^L = W^L a^{L-1} + b^L; \quad C(a^L(Z^L))$

- Ahora veamos el error imputado a cada neurona:

- $\frac{\partial C}{\partial z^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} = \delta^L$

- Si este valor es grande, significa que cambios en esa neurona afectan claramente el resultado final.

- Podemos re-escribir....

# Backpropagation

- Ahora podemos aplicar la regla de la cadena y obtener:

- $\frac{\partial C}{\partial w^L} = \delta^L a_i^{L-1}$

- $\frac{\partial C}{\partial b^L} = \delta^L$

- Recordemos que:

- $Z^L = W^L a^{L-1} + b^L; \quad C(a^L(Z^L))$



# Backpropagation

- Resumiendo:

- $\delta^L = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L}$

- $\frac{\partial C}{\partial w^L} = \delta^L a_i^{L-1}$

- $\frac{\partial C}{\partial b^L} = \delta^L$

- Con esto tenemos lo necesario para la última capa.
- Vamos por el resto...

# Backpropagation

- Para la capa L-1 y las anteriores, debemos considerar:
- $C(a^L(W^L a^{L-1}(W^{L-1} a^{L-2} + b^{L-1}) + b^L))$
- Aplicando la regla de la cadena

$$\begin{aligned}
 \bullet \quad \frac{\partial C}{\partial w^L} &= \underbrace{\left( \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \right)}_{\delta^L} \underbrace{\left( \frac{\partial z^L}{\partial a^{L-1}} \right)}_{\text{Derivada función activación}} \underbrace{\left( \frac{\partial a^{L-1}}{\partial z^{L-1}} \right)}_{\text{Derivada función activación}} \left( \frac{\partial z^{L-1}}{\partial w^{L-1}} \right) \leftarrow a^{L-1} \\
 \bullet \quad \frac{\partial C}{\partial b^L} &= \underbrace{\left( \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \right)}_{\delta^L} \underbrace{\left( \frac{\partial z^L}{\partial a^{L-1}} \right)}_{\text{Derivada función activación}} \underbrace{\left( \frac{\partial a^{L-1}}{\partial z^{L-1}} \right)}_{\text{Derivada función activación}} \left( \frac{\partial z^{L-1}}{\partial b^{L-1}} \right) \leftarrow 1
 \end{aligned}$$

# Backpropagation

- Para la capa L-1 y las anteriores, debemos considerar:
- $C(a^L(W^L a^{L-1}(W^{L-1} a^{L-2} + b^{L-1}) + b^L))$
- Aplicando la regla de la cadena

$$\bullet \frac{\partial C}{\partial w^L} = \underbrace{\frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L}}_{\delta^L} \underbrace{\frac{\partial z^L}{\partial a^{L-1}}}_{W^L} \underbrace{\frac{\partial a^{L-1}}{\partial z^{L-1}}}_{\text{Derivada función activación}} \frac{\partial z^{L-1}}{\partial w^{L-1}} \leftarrow a^{L-1}$$

$$\bullet \frac{\partial C}{\partial b^L} = \underbrace{\frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L}}_{\delta^L} \underbrace{\frac{\partial z^L}{\partial a^{L-1}}}_{W^L} \underbrace{\frac{\partial a^{L-1}}{\partial z^{L-1}}}_{\text{Derivada función activación}} \frac{\partial z^{L-1}}{\partial b^{L-1}} \leftarrow 1$$

$$z^L = W^L a^{L-1} + b^L$$

# Backpropagation

- Para la capa L-1 y las anteriores, debemos considerar:
- $C(a^L(W^L a^{L-1}(W^{L-1} a^{L-2} + b^{L-1}) + b^L))$
- Aplicando la regla de la cadena

$$\bullet \frac{\partial C}{\partial w^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial a^{L-1}} \frac{\partial a^{L-1}}{\partial z^{L-1}} \frac{\partial z^{L-1}}{\partial w^{L-1}} \leftarrow a^{L-1}$$

$$\bullet \frac{\partial C}{\partial b^L} = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L} \frac{\partial z^L}{\partial a^{L-1}} \frac{\partial a^{L-1}}{\partial z^{L-1}} \frac{\partial z^{L-1}}{\partial b^{L-1}} \leftarrow 1$$

$$\frac{\partial C}{\partial z^{L-1}} = \delta^{L-1}$$

# Backpropagation

- Cómputo del error de la última capa

$$\delta^L = \frac{\partial C}{\partial a^L} \frac{\partial a^L}{\partial z^L}$$

- Retropropagación del error a la capa anterior

$$\delta^{l-1} = W^l \delta^l \frac{\partial a^{l-1}}{\partial z^{l-1}}$$

- Calculo de las derivadas de la capa usando en error.

$$\frac{\partial C}{\partial b^{l-1}} = \delta^{l-1} \quad \frac{\partial C}{\partial w^{l-1}} = \delta^{l-1} a^{l-2}$$